Servicio Nacional de Aprendizaje
SENA
Proceso de Gestión de Formación Profesional Integral

# Solución de la Guía de Aprendizaje No. 1

Resumen de temas del trimestre I

Autor: Diego Esteban González Urrea
Ficha: 3533558
Docente: Ing. Nathalia Martinez Vargas

Procesamiento de Datos para Modelos de Inteligencia Artificial
Trimestre II
Centro de Materiales y Ensayos

Fecha de entrega: 31 de octubre del 2026, 11:59 p.m.
Fecha de Solución: 31 de Octubre del 2026, 10:30 p.m.
Bogotá D.C.

# Índice

**1. Presentación** **1**

**2. Actividades** **1**

2.1. Actividades de reflexión inicial . . . . . 1

2.2. Actividades de contextualización e identificación de conocimientos . . . . . 2

2.2.1. Fase 1 del Proyecto Integrador . . . . . 2

2.2.2. Resultados de la Fase 1 del Proyecto Integrador . . . . . 2

2.3. Actividades de apropiación . . . . . 3

2.3.1. Fase 2 del Proyecto Integrador . . . . . 3

2.3.2. Resultados de la Fase 2 del Proyecto Integrador . . . . . 3

2.4. Actividades de transferencia de conocimiento . . . . . 5

2.4.1. Fase 3 del Proyecto Integrador . . . . . 5

2.4.2. Resultados de la Fase 3 del Proyecto Integrador . . . . . 5

**3. Conclusiones** **6**

**Referencias** **7**

# 1. Presentación

¡Bienvenidos al Trimestre II del programa técnico en Procesamiento de Datos para Modelos de Inteligencia Artificial! En el mundo de la Inteligencia Artificial hay una regla de oro: el mejor algoritmo del mundo no sirve de nada si los datos que lo alimentan no son de excelente calidad. Dominar este ciclo de preparación de los datos fortalecerá su pensamiento analítico y le dará las herramientas necesarias para resolver problemas complejos de la vida real. Para hacer este repaso más sencillo y organizado, se ha dividido la ruta en 4 ejes clave:

- **Eje 1 - Fuentes y Formatos:** Buscar y extraer datos crudos de portales de datos (Datos Abiertos de Bogotá, Datos Abiertos Colombia, Kaggle o OpenML) y entender archivos comunes como CSV o Excel.
- **Eje 2 - SQL:** Hacerle ”preguntas” a las bases de datos relacionales para filtrar, agrupar y organizar solo la información que interesa.
- **Eje 3 - Exploración con Python y Pandas:** Usar código para cargar esos datos, revisar su estructura física e identificar qué les falta o qué está duplicado.
- **Eje 4 - Limpieza y Análisis (EDA):** Transformar esos datos crudos eliminando errores y aplicar el Análisis Exploratorio.

# 2. Actividades

## 2.1. Actividades de reflexión inicial

1. Si un error tan “básico” como no revisar las unidades de medida destruyó un proyecto de 125 millones de dólares en la NASA, ¿qué consecuencias podría tener para una empresa actual procesar un archivo de Excel sin saber si la columna “Ventas” está en pesos colombianos, dólares o euros?

   *Las consecuencias que puede tener 1 empresa al no saber qué tipo de datos tiene 1 columna de “Ventas” u otras columnas con Variables Cuantitativas es 1 error muy grande, pues no se conoce bien la estructura del documento al transformar y generar informes de esos datos. Para tomar decisiones o, como en el caso, perder 125 Millones de Dólares National Aeronautics and Space Administration 1999, demuestra una mala estructura de control de cómo manejar estos datos dentro del negocio.*

2. Teniendo en cuenta el caso de la sonda espacial, ¿por qué cree que la ficha de caracterización de variables (diccionario de datos) es el paso más importante antes de empezar a escribir código en Python o SQL?

*Un buen ejemplo del porqué esta ficha de caracterización de variables o diccionario de datos funciona antes de empezar a realizar código en Python o SQL: un buen proyecto arquitectónico tiene planos antes de empezar a construir una obra, para que los cimientos funcionen para cualquier proyecto y especificaciones del negocio, haciendo que sea sencillo para cualquier persona seguir la lógica del negocio con los datos y entender para qué se requieren utilizar.*

3. Si mañana llega a su primer trabajo y el gerente le entrega un archivo (.csv, .xlsx o .json) lleno de números sin ninguna explicación (sin metadatos), ¿cuál debería ser su primera acción como analista de datos antes de aplicar cálculos o transformaciones?

   *Lo que realizaría al tener 1 base de datos sin especificaciones de mi Jefe directo es entender y construir un diccionario de datos, para comprender y presentarle mis suposiciones sobre cómo se van a usar esos datos. Y si hay cambios o mejoras, modificar el diccionario. Después de esta estructuración de los datos, validar con mi jefe qué quiere obtener de ellos: construir 1 modelo de I.A. o resolver dudas de negocio realizando consultas al dataset con buenas estrategias para tomar decisiones.*

4. Hoy en día existe una obsesión por tener "Big Data" (millones de registros). A partir del caso de estudio, ¿de qué sirve tener millones de datos y las mejores herramientas si se comete un fallo en la etapa de comprensión estructural del dato?

   *No serviría de nada. Muchas empresas quieren migrar a tomar decisiones y no reconocen que no sirve tener tanta información si no cuentan con una buena estructura de control de datos dentro del negocio para mejorar la toma de decisiones, o sin una buena estrategia y comunicación de cómo se utiliza un dato entre diferentes áreas de trabajo.*

## 2.2. Actividades de contextualización e identificación de conocimientos

### 2.2.1. Fase 1 del Proyecto Integrador

Usted debería buscar y seleccionar de forma autónoma un conjunto de datos (dataset) de su interés en los portales de Datos Abiertos Bogotá D.C., OpenML o Kaggle. Una vez seleccionado, analizará el contexto de la información y deberá plantear al menos tres (3) preguntas de negocio que puedan ser respondidas con esos datos.

### 2.2.2. Resultados de la Fase 1 del Proyecto Integrador

Se seleccionó en Kaggle el conjunto de datos «Crimen Colombia 2020–2026: Eventos Geo Depurados» Jiménez 2026, con registros desde el 01 de diciembre de 2019 hasta el 30 de enero de 2026. Puede consultarse en Kaggle.

Y las preguntas de negocio que quiero resolver con este dataset van a ser las siguientes:

- ¿El día de las madres crece el crimen de violencia intrafamiliar con respecto a los crímenes cometidos en 1 día promedio del año?
- ¿Cuál fue el crimen más cometido por cada año?
- ¿Qué ciudad tiene mayor cantidad de crímenes cometidos dentro del periodo de tiempo del dataset?

## 2.3. Actividades de apropiación

### 2.3.1. Fase 2 del Proyecto Integrador

Usando el dataset elegido en la actividad anterior, desarrolle:

- Estructurar la ficha de caracterización (diccionario de variables) detallando cada columna.
- Utilizando Google Colab, importará el archivo plano (.csv o .xlsx), aplicará librerías y funciones de Python que conozca para realizar la limpieza de los datos: identificación y tratamiento de nulos, eliminación de duplicados, ajuste de tipos de datos, y los que considere necesarios.
- Generar un Análisis Exploratorio de Datos (EDA), incluya gráficos que considere necesarios para entender cómo se relacionan las variables entre sí.

### 2.3.2. Resultados de la Fase 2 del Proyecto Integrador

Usando el dataset elegido en la actividad anterior, desarrolle:

- **Estructurar la ficha de caracterización (diccionario de variables) detallando cada columna:** De manera técnica y estructurada un diccionario de datos oficial bajo buenas prácticas de gobernanza de datos DAMA International 2017, con 14 variables que componen el dataset de criminalidad en Colombia (período 2020-2026). Para cada columna se documentó su tipo de dato técnico en Pandas, su clasificación estadística (Cualitativa Nominal/Ordinal, Cuantitativa Discreta), una descripción detallada, ejemplos prácticos de sus registros y observaciones analíticas relevantes. Dicha ficha fue exportada en formatos interoperables (.json y .xlsx) en el almacenamiento oficial de Google Drive.

- **Importación del archivo plano, aplicación de librerías y funciones de Python para la limpieza de datos (ETL):** Se realizó la ingesta del archivo plano 'crimen_colombia_2020_2026_eventos_geo.csv' utilizando la librería Pandas y herramientas avanzadas de data wrangling McKinney 2017. Posteriormente, se ejecutó un proceso robusto de ETL para optimizar la calidad de los datos:
  - *Tratamiento de Nulos:* Se identificaron valores faltantes en 'armas_medios' (16,96 %), 'genero' (7,04 %), 'agrupa_edad_persona' (0.55 %) y 'municipio' ($< 0{,}01$ %). Se aplicó una estrategia de preservación de registros imputando los nulos con la categoría 'NO REPORTADO' (asegurando previamente la adición de este nivel en las variables categóricas).
  - *Ajuste de Tipos de Datos:* La columna 'fecha_hecho' fue transformada exitosamente de formato texto a tipo temporal (datetime64). Las columnas 'mes' y 'codigo_dane' se convirtieron a enteros utilizando el tipo nullable 'Int64' de Pandas para remover representaciones decimales inexactas.
  - *Optimización de Memoria RAM:* Las columnas 'departamento', 'genero', 'agrupa_edad_persona' y 'tipo_outlier' se transformaron al tipo especial 'category'. Esto redujo drásticamente el consumo en memoria RAM del DataFrame de 1,198.63 MB a solo 783.86 MB (una optimización de aproximadamente el 34.6 %).
- **Generar un Análisis Exploratorio de Datos (EDA) con soporte gráfico:** Se implementó un análisis gráfico multivariado y univariado empleando Matplotlib y Seaborn, siguiendo las etapas de comprensión y preparación de datos descritas en el ciclo de vida CRISP-DM Shearer 2000:
  - Distribución porcentual de los registros por género (Gráfico de torta) y grupo de edad (Gráfico de barras), demostrando que la gran mayoría de incidentes involucran a la categoría de 'ADULTOS'.
  - Gráfico de barras horizontales identificando el Top 10 de delitos, liderado ampliamente por el Hurto a Personas, Violencia Intrafamiliar y Lesiones Personales.
  - Evaluación temporal del volumen de crímenes por año, esclareciendo analíticamente la anomalía técnica de la baja en registros del 2026 debido a la carga de datos parciales (solo del mes de enero).
  - Mapa de calor de frecuencias cruzadas (Análisis Bivariado) correlacionando los Top 5 Delitos con los Top 5 Medios/Armas utilizados, lo que expuso visualmente cómo la 'Violencia Intrafamiliar' se ejecuta preponderantemente sin empleo de armas o mediante contundentes.
  - Análisis de consistencia léxica que permitió hallar duplicados de escritura en los municipios (como 'Paez'/'Páez' y 'Chima'/'Chimá') debido a la ausencia de tildes.

Como resultado directo de esta fase, se consolidó un conjunto de datos completamente limpio, estructurado y optimizado denominado 'crimen_colombia_limpio.csv' almacenado en la ruta de

trabajo, junto con el diccionario de variables en JSON y Excel, y un cuaderno parametrizado capaz de reproducir los análisis visuales y detectar cualquier inconsistencia léxica o de registros nulos de manera automatizada.

## 2.4. Actividades de transferencia de conocimiento

### 2.4.1. Fase 3 del Proyecto Integrador

Con el dataset completamente limpio e importado en un entorno de base de datos relacional (como SQLiteOnline o integrado en Colab), responda a las 3 preguntas de negocio formuladas en la fase de contextualización. Para ello, diseñará y ejecutará consultas en SQL (usando SELECT, WHERE, GROUP BY, JOIN, etc.). Finalmente, consolide todo el proyecto en un reporte único donde presentará las consultas realizadas y las conclusiones estratégicas que obtuvo a partir de los datos.

### 2.4.2. Resultados de la Fase 3 del Proyecto Integrador

Se configuró con éxito un servidor local de base de datos relacional MySQL dentro del entorno de Google Colab. Mediante la librería SQLAlchemy, se estructuró la base de datos 'proyecto_crimen' y se cargó la totalidad del conjunto de datos limpio bajo la tabla relacional 'eventos_crimen'.

Se diseñaron y ejecutaron consultas estructuradas en SQL para dar respuesta a las 3 preguntas estratégicas planteadas:

1. **Pregunta 1: Violencia Intrafamiliar en Mayo (Día de la Madre) vs. Promedio Diario Anual** La consulta SQL implementó expresiones de tabla comunes (CTEs) utilizando filtros complejos (LIKE, MONTH y operadores aritméticos) para promediar la violencia intrafamiliar. La consulta arrojó la tendencia e incrementos específicos año a año en los promedios diarios de Mayo frente al resto del año escolar.

2. **Pregunta 2: Crimen más cometido por cada Año** Mediante el uso de la función de ventana analítica `ROW_NUMBER() OVER (PARTITION BY anio ORDER BY SUM(cantidad) DESC)`, se estructuró un query de alta precisión que determinó el delito dominante para cada año fiscal. El reporte evidenció de forma unánime que el *.ARTÍCULO 239. HURTO PERSONAS"* se posiciona como el crimen con mayor cantidad de eventos anuales de manera sostenida.

3. **Pregunta 3: Ciudad/Municipio con mayor cantidad de crímenes cometidos** A través de agrupaciones espaciales y la aplicación de funciones de agregación (`SUM` y `COUNT`), la consulta determinó con precisión que el municipio con la mayor carga de criminalidad y

volumen de registros dentro del territorio nacional corresponde a **Bogotá D.C. (CT)** en el departamento de **Cundinamarca**.

Este proceso demuestra de manera integral la viabilidad tecnológica de conectar la suite de ciencia de datos de Python con motores de bases de datos relacionales tradicionales (SQL) para resolver problemas analíticos empresariales y de políticas públicas.

# 3. Conclusiones

1. **Importancia de la gobernanza y comprensión del dato:** El desarrollo del proyecto demostró que la construcción previa de un diccionario de datos y la etapa de control estructural (ETL) son indispensables antes de ejecutar modelos analíticos o de Inteligencia Artificial. Identificar inconsistencias léxicas, ajustar tipos de datos y definir categorías redujo el consumo de memoria en un 34,6 % y garantizó la integridad de la información, evitando decisiones erróneas basadas en datos ambiguos.

2. **Sinergia entre la ciencia de datos y bases de datos relacionales:** La integración exitosa entre el ecosistema de Python (*Pandas*, *SQLAlchemy*) y un motor relacional MySQL validó la viabilidad de procesar grandes volúmenes de datos abiertos. La combinación de análisis exploratorio gráfico con la ejecución de consultas avanzadas en SQL (*CTEs* y funciones de ventana como `ROW_NUMBER()`) permitió extraer patrones complejos con alto rendimiento computacional.

3. **Valor estratégico para la toma de decisiones:** Las consultas SQL automatizadas permitieron determinar que el hurto a personas es el delito predominante de forma constante (2020-2026) y que Bogotá D.C. concentra el mayor volumen de eventos en el país. Este tipo de hallazgos demuestra cómo el procesamiento técnico de datos convierte registros crudos en evidencia cuantitativa clave para la formulación de políticas públicas de seguridad y la optimización de recursos institucionales.

# Referencias

DAMA International. (2017). *DAMA-DMBOK: Data Management Body of Knowledge* (2nd). Technics Publications.

Jiménez, W. (2026). Crimen Colombia 2020–2026: Eventos Geo Depurados [Conjunto de datos]. https://www.kaggle.com/datasets/williamajg/crimen-colombia-2020-2026-eventos-geo-depurados

McKinney, W. (2017). *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython* (2nd). O'Reilly Media.

National Aeronautics and Space Administration. (1999). *Mars Climate Orbiter Mishap Investigation Board Phase I Report* (inf. téc.). NASA. Washington, D.C.

Shearer, C. (2000). The CRISP-DM Model: Clean Hands Environment for Data Mining. *Journal of Data Warehousing*, *5*(4), 13-22.